

Automatické ověřování podpisu: Současný stav techniky

Donato Impedovo a Giuseppe Pirlo, členové, IEEE

Abstrakt V posledních letech, spolu s mimořádným rozšířením internetu a rostoucí potřebou ověřování osob v mnoha každodenních aplikacích, se s obnoveným zájmem uvažuje o automatickém ověřování podpisů. Tento článek představuje současný stav techniky v oblasti automatického ověřování podpisů. Zabývá se nejcennějšími dosud dosaženými výsledky a upozorňuje na nejpřínosnější směry dosavadního výzkumu. Obsahuje obsáhlou bibliografii více než 300 vybraných odkazů jako pomůcku pro výzkumníky pracující v této oblasti.

Rejstříkové termíny - biometrie, ověřování osob, ověřování podpisu, bezpečnost systému.

I. ÚVOD

TPOŽADAVKY NA BEZPEČNOST dnešní společnosti postavily biometrii do centra rozsáhlé debaty, protože se jedná o

se stává klíčovým aspektem v mnoha aplikacích [19], [262], [370]. Termín biometrie označuje rozpoznávání osob na základě jejich rozlišovacích znaků. Zatímco jiné techniky využívají k rozpoznávání osob vlastnictví tokenu (tj. odznaku, identifikační karty atd.) nebo znalost něčeho (tj. hesla, klíčové fáze atd.), biometrické techniky nabízejí možnost využít k tomuto úkolu vrozené vlastnosti rozpoznávané osoby. Biometrické atributy tak netrpí nevýhodami ani přístupů založených na tokenech, jejichž atributy lze ztratit nebo odcizit, ani přístupů založených na znalostech, jejichž atributy lze for- govat [137], [325].

Biometrický systém může buď ověřovat, nebo identifikovat. V ověřovacím režimu ověřuje totožnost osoby na základě její deklarované identity. Naopak v režimu identifikace zjišťuje identitu osoby (mezi osobami zapsanými v databázi), aniž by subjekty musely svou identitu tvrdit [139], [325]. V závislosti na uvažovaných osobních rysech lze definovat dva typy biometrik: fyziologické nebo behaviorální. První z nich jsou založeny na měření biologických znaků uživatelů, jako jsou například otisk prstu, obličej, geometrie ruky, sítnice a duhovka. Druhé berou v úvahu behaviorální znaky uživatelů, jako je hlas nebo vlastnoruční podpis [19], [139], [322], [325], [370].

Hodnocení biometrie je mnohostranný problém [139], [326], [336]. Biometrický znak by například měl být *univerzální*,

Rukopis přijat 2. března 2007; revidován 3. srpna 2007 a 7. listopadu 2007. Tento článek byl doporučen spolupracujícím redaktorem M. Lastem.

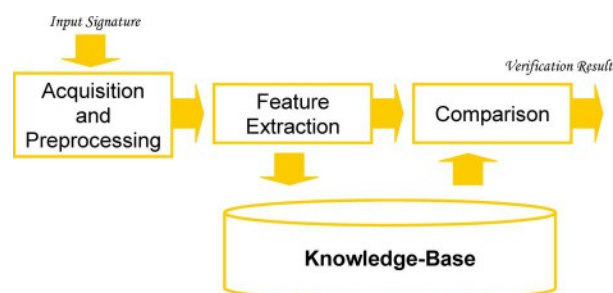
D. Impedovo působí na Dipartimento di Elettrotecnica ed Elettronica, Politecnico di Bari, Bari 70126, Itálie, a také na Centro "Rete Puglia," Università degli Studi di Bari, Bari 70124, Itálie (e-mail: impedovo@deemail.poliba.it).

G. Pirlo působí v Dipartimento di Informatica, Università degli Studi di Bari, Bari 70126, Itálie a také v Centro "Rete Puglia," Università degli Studi di Bari, Bari 70124, Itálie (e-mail: pirlo@di.uniba.it).

Barevné verze jednoho nebo více obrázků v tomto článku jsou k dispozici online na adrese <http://ieeexplore.ieee.org>.

Identifikátor digitálního objektu 10.1109/TSMCC.2008.923866

Oprávněné licencované použití je omezeno na: IEEE Xplore. Staženo 3. listopadu 2008 v 10:43 z IEEE Xplore. Platí omezení.



Obr. 1. Proces ověřování podpisu.

tj. každý člověk by měl vlastnit daný znak; *jedinečný*, tj. žádné dvě osoby by neměly mít stejný znak; *trvalý*, tj. znak by se neměl měnit ani být změníteľný; *sbíratelný*, tj. znak lze snadno získat. Kromě toho by se návrh biometrického systému měl zabývat i dalšími žádoucími vlastnostmi, jako je přesnost, nákladová a rychlostní efektivita, přijatelnost pro uživatele atd [127], [322].

Ačkoli se dosud uvažovalo o širokém souboru biometrických údajů, je třeba poznamenat, že žádný znak není schopen zcela uspokojit všechny žádoucí vlastnosti požadované pro biometrický systém [137]. Posouzení biometrického znaku je tedy silně závislé na konkrétní aplikaci, protože zahrnuje nejen technické otázky, ale také sociální a kulturní aspekty [137], [322], [325].

V tomto širokém souboru biometrických znaků zaujímají ručně psané podpisy velmi zvláštní místo [78], [81], [165], [248], [258]. Je to dáno především tím, že vlastnoruční podpisy se již dlouho etablovaly jako nejrozšířenější prostředek osobní verifikace. Podpisy jsou obecně uznávány jako legální prostředek ověření identity jednotlivce správnými a finančními institucemi [225], [336]. Ověřování pomocí analýzy podpisu navíc nevyžaduje žádná invazivní měření a lidé jsou s používáním podpisů v každodenním životě fa- miliární [259].

Vlastnoruční podpis je bohužel výsledkem složitého procesu, který závisí na psychofyzickém stavu podepisující osoby a na podmínkách, za kterých k podpisu dochází. Ačkoli tedy byly navrženy komplexní teorie modelující psychofyzické mechanismy, které jsou základem rukopisu [253]-[256] a procesů ukládání inkoustu [62], [99], [100], [101], zůstává ověřování podpisu stále otevřenou výzvou, protože podpis je posuzován jako pravý nebo padělaný pouze na základě několika referenčních vzorků [250]. Na obr. 1 jsou načrtnuty tři hlavní fáze automatického ověřování podpisů: získávání a předzpracování dat, extrakce příznaků a klasifikace. Ve fázi zápisu se zpracovávají vstupní podpisy a extrahují se jejich osobní rysy, které se ukládají do znalostní báze. Ve fázi klasifikace se porovnávají osobní rysy extrahované ze vstupního podpisu.

1094-6977/\$25.00 © 2008 IEEE

s informacemi ve znalostní bázi, aby bylo možné posoudit pravost zadaného podpisu.

Automatické ověřování podpisů zahrnuje aspekty z různých oborů, od lidské anatomie po inženýrství, od neurovědy po informatiku a systémovou vědu [196]. Vzhledem k této skutečnosti přitahují v posledních letech studie o ověřování podpisů výzkumníky z různých oborů, pracující pro univerzity a společnosti, které se zajímají nejen o vědecké výzvy, ale také o cenné aplikace, které tento obor nabízí [229]. Obsáhlé přehledové práce informovaly o pokroku v oblasti automatického ověřování podpisů do roku 1993 [165], [258], [291]. V roce 1994 bylo vydáno zvláštní číslo a kniha shrnující nejdůležitější výzkumné aktivity [251]. Následně byly v různých článcích shrnuty rostoucí výzkumné snahy v této oblasti [52], [58], [224], [248], [280] také s ohledem na obecnější oblast rukopisu analýzy a zpracování [259].

V souvislosti s nedávným mimořádným rozvojem internetu se s novým zájmem uvažuje o automatickém ověřování podpisů. Vytvoření zvláštních zákonů a předpisů, které byly schváleny v mnoha zemích [173], [336], a pozornost, kterou několik národních asociací a mezinárodních institutů věnuje standardizaci formátů pro výměnu podpisových dat [10], [135], [136], jsou důkazem opětovného zvýšení pozornosti v této oblasti. Cílem těchto snah je usnadnit integraci technologií pro ověřování podpisů do dalších standardních zařízení a vytvořit tak kompletní řešení pro širokou škálu komerčních aplikací, jako je bankovníctví, pojišťovnictví, zdravotnictví, zabezpečení dokladů, správa dokumentů, elektronické obchodování a maloobchodní prodejní místa (POS) [78], [259], [320].

Tento článek představuje současný stav techniky v oblasti automatického ověřování značek se zvláštním zřetelem na nejnovější pokroky. Po představení fází procesu verifikace signatury jsou popsány hlavní přínosy výzkumných aktivit v posledních letech a diskutovány nejslibnější trendy. Konkrétně oddíl II představuje hlavní aspekty týkající se získávání a předběžného zpracování dat a oddíl III se zabývá fází extrakce příznaků. Oddíl IV popisuje výzkumné činnosti týkající se fáze klasifikace, zatímco oddíl V shrnuje výkonnost systémů pro automatické ověřování podpisu uváděných v literatuře. V oddíle VI je uvedena stručná diskuse o aplikacích automatického ověřování podpisů a nejslibnějších směrech výzkumu a závěry tohoto článku. Pro větší zájem čtenářů je uvedena také bibliografie s více než 300 odkazy. Zahrnuje nejdůležitější nedávno publikované práce i některé starší práce, které mohou pomoci podat ucelený přehled o vývoji v této oblasti výzkumu.

II. SBĚR A PŘEDBĚŽNÉ ZPRACOVÁNÍ DAT

Na základě způsobu získávání dat lze rozlišit dvě kategorie systémů pro ověřování vlastnoručních podpisů: statické (offline) systémy a dynamické (online) systémy [132]. Statické systémy využívají offline zařízení pro sběr dat, která je sbírají až po dokončení procesu psaní. V tomto případě je podpis reprezentován jako obraz $\{S(x,y)\}_{0 \leq x \leq X, 0 \leq y \leq Y}$, kde $S(x,y)$ označuje úroveň šedi na pozici (x,y) obrazu. Dynamické systémy místo toho používají zařízení pro online sběr dat, která generují elektronickou

(a)

(b)

Obr. 2. Statické/dynamické signatury. (a) Statická signatura. (b) Dynamický podpis ("*" : perem dolů; "-" : perem nahoru).

signály reprezentující podpis během procesu psaní. V tomto případě je podpis reprezentován jako sekvence $\{S(n)\}_{n=0, 1, \dots, N}$, kde $S(n)$ je hodnota signálu vzorkovaného čas n při hodnotě

Δt procesu podepisování ($0 \leq n \leq N$), přičemž Δt je časový úsek

období odběru vzorků. Proto se v offline případě jedná o zpracování prostorové svítivosti obrazu signatury [viz obr. 2(a)], zatímco v online případě jde o zpracování prostorové reprezentace signatury [viz obr. 2(b)].

Nejtradičnějšími zařízeními pro online akvizici jsou digitalizační tablety [115]. Používání digitalizačních tabletů samozřejmě není zdaleka samozřejmé a bylo učiněno mnoho pokusů o výrobu elektronických per, která by byla pro uživatele přijatelnější a zároveň by se dala snadno integrovat do současných systémů [121], [300], [314]. Dobrým příkladem takových snah jsou elektronická pera s dotykovými obrazovkami a technologie digitálního inkoustu, které zabraňují dezorientaci podepisujícího tím, že pisatelé poskytují okamžitou zpětnou vazbu [5], [6]. Elektronická pera jsou také schopna zjišťovat polohu, rychlost, zrychlení, tlak, sklon pera a síly při psaní, a to pomocí tenzometrů [46], magnetoelastických senzorů [374], posunu rezonanční frekvence [237] a laserových diod [300]. Některá zařízení input používají inkoustové pero, což je úplně stejné jako při použití běžného pera na standardním papíře umístěném na tabletu. V tomto případě pero vytváří konvenční rukopis pomocí inkoustu, přičemž vytváří přesnou elektronickou repliku skutečného rukopisu. Výhodou je možnost zaznamenávat data online i offline současně a umožnit velmi přirozené psaní, protože se používá téměř standardní pero a papír [106], [239]. Obecně lze říci, že rozvoj digitalizačních zařízení, od tradičních stolních tabletů až po nejnovější praktické tablety s digitalizátorem [158], osobní digitální asistenty (PDA) [266] a vstupní zařízení pro mobilní počítače [5], [6], [72], [74], [261], přináší nové problémy týkající se interoperability zařízení, tj. schopnosti ověřovacího systému přizpůsobit se datům získaným z různých zařízení. Jedním z příkladů je ověřování podpisů pomocí myši, které bylo předmětem specifického výzkumu vzhledem k jeho významu v internetových transakcích [173], [313]. Jiné přístupy zachycují rukopis pomocí technik počítačového vidění. Nedávno byl například navržen speciální stylus nesoucí malou kameru s nábojovou vazbou (CCD), která zachycuje sérii snímků písma [219]. Systém obnovuje celou stopu rukopisu analýzou sekvence po sobě jdoucích snímků. Stylus je také vybaven snímačem napětí pro detekci tlaku vyvíjeného na kuličkové pero a určení informace o zvednutí/spuštění pera. Existují také alternativní přístupy, které nevyžadují použití

speciálního stylusu a místo toho využívají videokameru, která je zaměřena

TABULKA I
SEGMENTAČNÍ TECHNIKY

Technique	Category	References
Segmentation by Pen-down/Pen-up Signals	Online	G. Dimauro et al. [54, 56], Herbst and Liu [121], R. Plamondon [252], C. Schmidt and K.-F. Kraiss [298], Y. Xuhua et al. [352, 353, 354]
Segmentation by Velocity Signal Analysis	Online	H.Y. Kwon et al. [162], R. Plamondon et al [260]
Segmentation by Perceptually relevant points.	Online	J.J. Brault and R. Plamondon [21], M.M.Shafiei and H.R. Rabiee [299], K.W. Yue and W.S. Wijesoma [369]
Segmentation by Dynamic Time Warping	Online	L. Bovino et al. [18], S. Chen and S. N. Srihari [33], V. Di Lecce et al. [50], G. Dimauro et al. [55], J. Lee et al. [166], W.-S. Lee et al. [172], T.H. Rhee et al. [275]
Segmentation by Connected Components	Offline	G. Congedo et al. [41], G. Dimauro et al. [57, 59]
Segmentation by Tree Structure Analysis	Offline	M. Ammar et al [8]
Segmentation by Statistics of Directional Data	Offline	K. Huang and H.Yan [127], R. Sabourin and R.Plamondon [287, 289]

na uživatele při psaní na papír běžným perem [24], [210], [355]. Tímto způsobem se rukopis obnovuje z časoprostorové reprezentace dané sekvencí snímků. Tento přístup může být nejjednodušším způsobem, jak může uživatel pomocí rukopisu komunikovat s počítačem, a jeho potenciál byl konkrétně prokázán v oblasti automatického ověřování podpisů [207], [209], [211]. Kromě toho bylo pro online ověřování podpisu použito zařízení s rukavicemi pro aplikace virtuální reality [317]. Toto zařízení může poskytovat údaje jak o dynamice pohybu pera při podepisování, tak o tvaru ruky jednotlivce.

Ve fázi předzpracování je vylepšení vstupních dat obvykle založeno na technikách pocházejících ze standardních algoritmů zpracování signálu [242].

Pokud se uvažuje o statických podpisech, typické algoritmy předzpracování se týkají extrakce podpisu [59], [61], odstranění šumu pomocí mediánových filtrů [15], [17], [126] a morfologických algoritmů.

operátory [126], [263], normalizace velikosti podpisu [17], [263],

binarizace [126], ztenčování [17], [359] a rozmazávání [126], [283]. V této oblasti je důležitou otázkou zpracování statických obrazů podpisů na bankovních šecích, protože zpracování bankovních šeků zůstává pro vědeckou komunitu stále otevřenou výzvou [59]. Obrazy bankovních šeků jsou totiž velmi složité, protože obvykle obsahují barevné obrázkové pozadí, několik lo- gů a mnoho předtištěných pokynů. Zpracování obrazů sig- natur získaných z bankovního šeku je tedy velmi obtížné a vývoj systémů pro ověřování podpisů s přesností požadovanou bankami a dalšími finančními institucemi je oblastí pokračujícího výzkumu [39], [59], [60], [61], [171], [236], [367]. Za tímto účelem byly vyvinuty specifické hybridní systémy, které kombinují online a offline informace pro ověření vlastnoručního podpisu. Online referenční podpis, získaný prostřednictvím digitalizačního tabletu, slouží k předzpracování odpovídajícího naskenovaného offline obrazu podpisu. Tento druh hybridového systému se dobře hodí pro bankovní prostředí, kde je přítomnost zákazníka nutná k otevření nového účtu, ale není nutná při ověřování podpisů na šecích a jiných dokumentech [375], [376].


Typické algoritmy předzpracování pro dynamické ověřování podpisu

ifikační zahrnuje filtrování, redukci šumu a vyhlazování. K tomuto účelu se používá Fourierova transformace [146], [147], [379], matematická


ické morfologie [115] a Gaussovy funkce [37], [138],

[180] byly použity. Pro standardizaci signatur v oblasti polohy, velikosti, orientace a časového trvání byly zvažovány postupy normalizace signatur pomocí globálních referenčních

systémů (střed hmotnosti a hlavní osy setrvačnosti) [131] a Fourierovy transformace [7], [146], [147], [149], [203], [273].



(a)



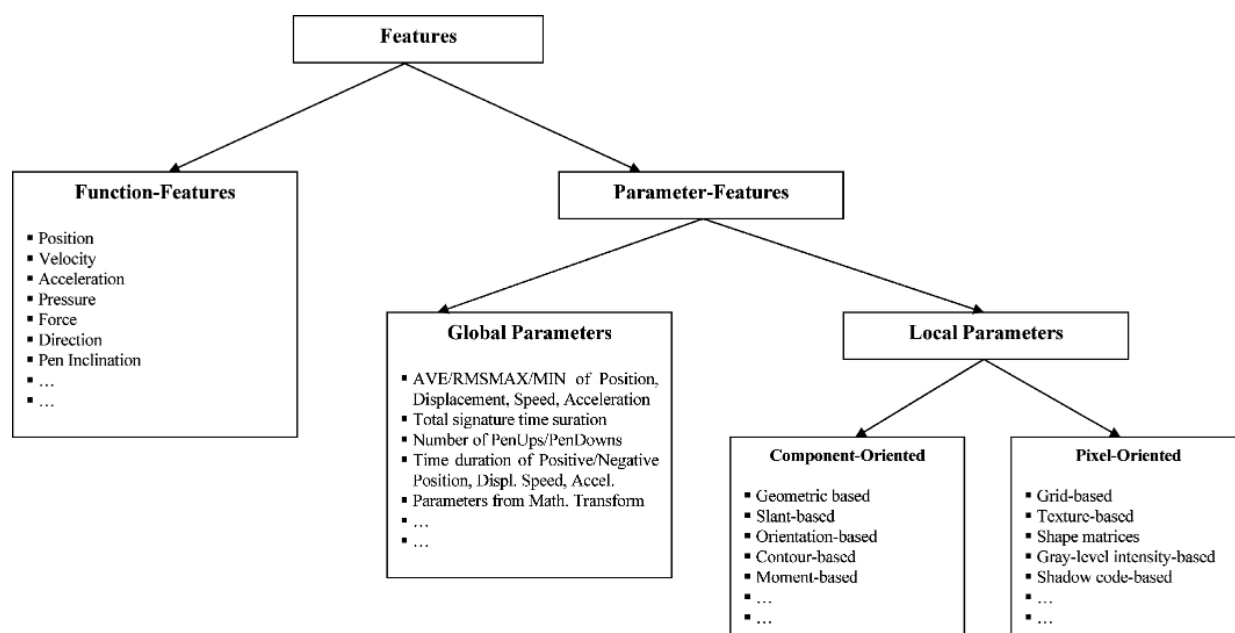
(b)

Obr. 3. Příklady segmentace podpisu. (a) Segmentace podpisu offline pomocí připojených komponent. (b) Online segmentace podpisu podle komponent ("*" : pero dolů; "-" : pero nahoru).

Klíčovým krokem předzpracování, který výrazně ovlivňuje všechny následující fáze ověřování podpisu, je segmentace. Segmentace podpisu je složitý úkol, protože různé podpisy vytvořené stejným pisatelem se mohou od sebe lišit v důsledku lokálního roztažení, komprese, vynechání nebo přidání dalších částí. Z tohoto důvodu byla segmentaci podpisů věnována zvláštní pozornost a bylo navrženo několik technik. Obecně lze říci, že některé segmentační techniky vycházejí ze specifických vlastností ručně psaných podpisů a odrážejí specifické modely rukopisu [54], [56], [252], [260]. Jiné techniky poskytují výsledky segmentace vhodné pro partikulární techniky používané k ověřování podpisů [55], [172]. Tabulka I uvádí některé z nejvýznamnějších technik pro segmentaci podpisu.

Nejjednodušší přístupy k segmentaci statických signatur vycházejí ze strukturálních popisů. Některé přístupy provádějí strukturální analýzu prostřednictvím identifikace propojených komponentů získaných algoritmy pro sledování obrysů [41], [57], [59]. Obr. 3(a) ukazuje signaturu na obr. 2(a) segmentovanou na propojené komponenty. Jiné přístupy popisují signaturu pomocí stromové struktury získané analýzou histogramů horizontální a vertikální projekce, která identifikuje fundamentální segmenty ve statickém obrazu [8]. Segmentace podpisu offline pomocí statistiky směrových dat byla také považována [287, 289]. Tento přístup umožňuje extrakci texturovaných oblastí, které se vyznačují lokální uniformitou v orientaci gradientu, vyhodnocenou pomocí Sobelova operátoru.

Pokud jde o dynamické signatury, některé segmentační techniky byly odvozeny přímo ze získaných signálů, které jsou reprezentativní pro vstupní signaturu. Rozšířená technika segmentace, která využívá informace o tlaku, je založena na úvaze, že na signaturu lze pohlížet jako na posloupnost psacích jednotek, ohraničených náhlými přerušováními [54], [56]; psaní



Obr. 4. Kategorie funkcí.

Jednotky jsou pravidelné části signatury, zatímco přerušení jsou singularity signatury. Signály nahoru/dolů se tedy používají k segmentaci podpisu na *složky*, přičemž každá *složka* je částí psané stopy mezi pohybem perem dolů a nahoru [54], [56], [121], [252], [298]. Navíc každý pisatel může vygenerovat pouze konečnou množinu *komponent*, jak dokazují experimentální důkazy, že singularity se mohou vyskytovat pouze v určitých pozicích v podpisu jedince [56]. Obr. 3b) ukazuje podpis z obr. 2b) rozčleněný na *komponenty*. Jiné přístupy používají k ověření podpisu výhradně tahy perem nahoru, protože tahy perem nahoru si počítač může zapamatovat, ale pro člověka jsou neviditelné. Proto je možnost záměrného napodobení těchto tahů malá [352]–[354].

Jiné segmentační techniky používají signály křivkové a úhlové rychlosti [260]. V jiných případech se segmentace podpisu provádí analýzou rychlostních signálů, v případě potřeby také s využitím statických rysů [162].

Jiná technika segmentace je založena na detekci percepčně důležitých bodů podpisu [21]. Důležitost bodu závisí na změně úhlu zápisu mezi vybraným bodem a sousedním bodem. Upravená verze této techniky považuje koncové body tahů perem dolů za významné body dělení [299]. Jiné přístupy používají pro segmentaci podpisů percepčně důležité body, zatímco pro asociaci segmentů uvažují evoluční míru vzdálenosti, založenou na vzdálenosti délky oblouku [369].

Aby bylo možné segmentovat dva nebo více podpisů na stejný počet dokonale odpovídajících segmentů, používá se pro segmentaci podpisů hojně dy- namické časové deformace (DTW) [55], [166], [172], [275]. Po rozdělení první signatury podle jednotných prostorových kritérií [172] nebo polohy geometrických extrémů [55], [166] se DTW použije k určení odpovídající množiny bodů na dalších speci- macích. Segmentační technika řízená modelem byla rovněž

[275]. Ten používá DTW k segmentaci vstupního podpisu podle jeho shody s referenčním modelem.

III. EXTRAKCE FUNKCÍ

Jak je znázorněno na obr. 4, pro ověření podpisu lze použít dva typy funkcí: funkce nebo parametry. Při použití funkčních rysů je podpis obvykle charakterizován časovou funkcí, jejíž hodnoty tvoří množinu rysů. Při použití parametrických rysů je podpis charakterizován jako vektor prvků, z nichž každý reprezentuje hodnotu rysu. Funkční rysy obecně umožňují lepší výkon než parametry, ale obvykle vyžadují časově náročné postupy pro porovnávání [258]. Kromě toho se parametry obecně dělí do dvou hlavních kategorií: globální a lokální. Globální parametry se týkají celého podpisu; typickými globálními parametry jsou celková doba trvání podpisu, počet zdvihů pera, počet komponent, globální orientace podpisu, koeficienty získané matematickými transformacemi atd. Lokální parametry se týkají rysů extrahovaných z konkrétních částí podpisu. V závislosti na uvažované úrovni podrobnosti lze lokální parametry rozdělit na parametry orientované na komponenty, které jsou extrahovány na úrovni jednotlivých komponent (tj. poměr výšky a šířky tahu, relativní pozice tahů, orientace tahu atd.), a na parametry orientované na pixely, které jsou extrahovány na úrovni pixelů (tj. informace založené na mřížce, hustota pixelů, intenzita šedi, textura atd.) Stojí za zmínku, že některé parametry, které jsou obecně považovány za globální rysy, lze použít i lokálně a *naopak*. Například rysy založené na obrysech lze extrahovat na globální úrovni (tj. obálky extrahované na úrovni celé signatury) nebo na lokální úrovni (tj. na úrovni každé připojené komponenty).

V tabulce II jsou uvedeny některé z nejčastějších funkčních vlastností nalezené v literatuře. Funkce polohy, rychlosti a zrychlení jsou široce využívány pro online ověřování podpisu. Poloha

TABULKA II
FUNKCE FUNKCE

Functions	Category	References
Position	Online / Offline	G. Congedo et al. [40], J. Fierrez-Aguilar et al. [94], Y. Hongo et al. [122], Y. Kato et al. [150], Y. Komiya et al. [159], S. Krawczyk and A. K. Jain [160], J. P. Leszczyska [177], Mizukami et al [199, 200], H. Morita et al. [205], D. Muramatsu and T. Matsumoto [212, 213, 214], I. Nakanishi et al. [221, 222, 223], T. Ohishi et al. [233, 234, 235], J. Ortega-Garcia et al. [238], J.D. Penagos et al. [245], D. Sakamoto et al. [292, 293], Y. Sato and K. Kogure [296], Q.-Z. Wu et al. [346]
Velocity	Online	A. I. Al-Shoshan [7], G. Congedo et al. [40], V. Di Lecce et al. [50, 51], M. Fuentes et al. [104], K. Huang and H. Yan [129], A.K. Jain et al. [138], G.V. Kiran et al. [158], J. Ortega-Garcia et al. [238], J.D. Penagos et al. [245], T. Qu et al. [266, 267], C. Schmidt and K.-F. Kraiss [298], J. Sternby [312], Q.-Z. Wu et al. [346], K. Yu et al. [368], K. Zhang et al. [372]
Acceleration	Online	G. Congedo et al. [40], N.M. Herbst and C.N. Liu [121], G.V. Kiran et al. [158], J.S. Lew [178, 179], J.D. Penagos et al. [245], C. Schmidt and K.-F. Kraiss [298], A.F. Syukri et al. [313]
Pressure	Online	J. Fierrez-Aguilar et al. [94], Y. Hongo et al. [122], K. Huang and H. Yan [129], Y. Kato et al. [150], M. Kawamoto et al. [151], Y. Komiya et al. [159], S. Krawczyk and A. K. Jain [160], H. Morita et al. [205], T. Ohishi et al. [233, 234, 235], J. Ortega-Garcia et al. [238], J.D. Penagos et al. [245], T. Qu et al. [266, 267], D. Sakamoto et al. [292, 293], Y. Sato and K. Kogure [296], C. Schmidt and K.-F. Kraiss [298], J. Sternby [312], K. Tanabe et al. [315], K. Yu et al. [368]
Force	Online	H.D. Crane and J.S. Ostrem [46], R. Martens and L. Claesen [187, 188, 189]
Direction of pen movement	Online	M. Fuentes et al. [104], J. J. Igarza et al. [130], I. Nakanishi et al. [222, 223], J. Ortega-Garcia et al. [239], I. Yoshimura and M. Yoshimura [363], M. Yoshimura et al. [366]
Pen inclination	Online	J. J. Igarza et al. [130], Y. Kato et al. [150], M. Kawamoto et al. [151], Y. Komiya et al. [159], R. Martens and L. Claesen [187, 188, 189], H. Morita et al. [205], T. Ohishi et al. [233, 234, 235], J. Ortega-Garcia et al. [238], D. Sakamoto et al. [292, 293], J. Sternby [312], K. Yu et al. [368]

je přenášena přímo snímacím zařízením, zatímco funkce rychlosti a zrychlení mohou být poskytovány jak snímacím zařízením [121], [178], tak numericky odvozeny z polohy [40], [51], [346]. V posledních letech se často používají funkce tlaku a síly a byla vyvinuta specifická zařízení, která tyto funkce snímají přímo během procesu signalizace [46], [219], [235], [237], [300], [374]. Zejména informace o tlaku, kterou lze zaznamenat s re- spektem na různá rychlostní pásma, byla využita pro ověřování podpisu s cílem využít interferenční závislosti [154]. Kromě toho se pro zlepšení výkonu při online ověřování podpisů úspěšně uvažovalo také o směru pohybu pera [363], [366] a sklonu pera [130], [151], [238], zatímco funkce trajektorie pera byly extrahovány ze statických podpisů, aby se využil potenciál dynamických informací i pro offline ověřování podpisů [226]. Nedávné studie také ukazují, že ověřování podpisů lze úspěšně provádět pomocí "motivových" řad, což jsou charakteristické podřetězce extrahované z funkcí [109].

Obecně platí, že funkce polohy, rychlosti a sklonu pera jsou při použití modelu konzistence založeného na vzdálenosti považovány za jedny z nejnezjistitelnějších prvků při online ověřování podpisu. Tento model vychází z úvahy, že vlastnosti rysu musí být odhadnuty také pomocí míry vzdálenosti přiřazené samotnému rysu [174].

V tabulce III jsou uvedeny některé vlastnosti parametrů, které byly široce zvažovány pro automatické ověřování podpisu. Některé parametry jsou věnovány speciálně dynamickému ověřování podpisů. To je případ některých globálních parametrů, které popisují proces připojování podpisů, jako je celková doba trvání podpisu [146], [147], [170], [266], doba odložení podpisu (pen-down time), doba, po kterou se podpis připojuje k podpisu (pen-down time) [146], [147], [227], [335] a počet zdvihů pera.

(pen-down, pen-up) [82], [166], [169], [170]. Další parametry jsou numericky odvozeny z časových funkcí reprezentativních pro signaturu, jako je například průměr (AVE), kořenový průměr (root mean), průměrná hodnota (AVE), průměrná hodnota (AVE), průměrná hodnota (AVE).

(rms) a maximální (MAX) a minimální (MIN) hodnoty polohy, posunu, rychlosti a zrychlení [169], [170], [227]. V jiných případech jsou parametry - které byly použity pro dynamické i statické ověření podpisu - de- terminovány jako koeficienty získané z matematických nástrojů, jako jsou Fourierovy [41], [54], [56], [57], [59], [194], [268], [345], [347],

Hadamard [228], kosinus [193], wavelet [49], [75], [76], [176], [189], [194], [195], [220], [274], [323], [332], [356], Radom [38] a fraktální [127], [206] transformace.

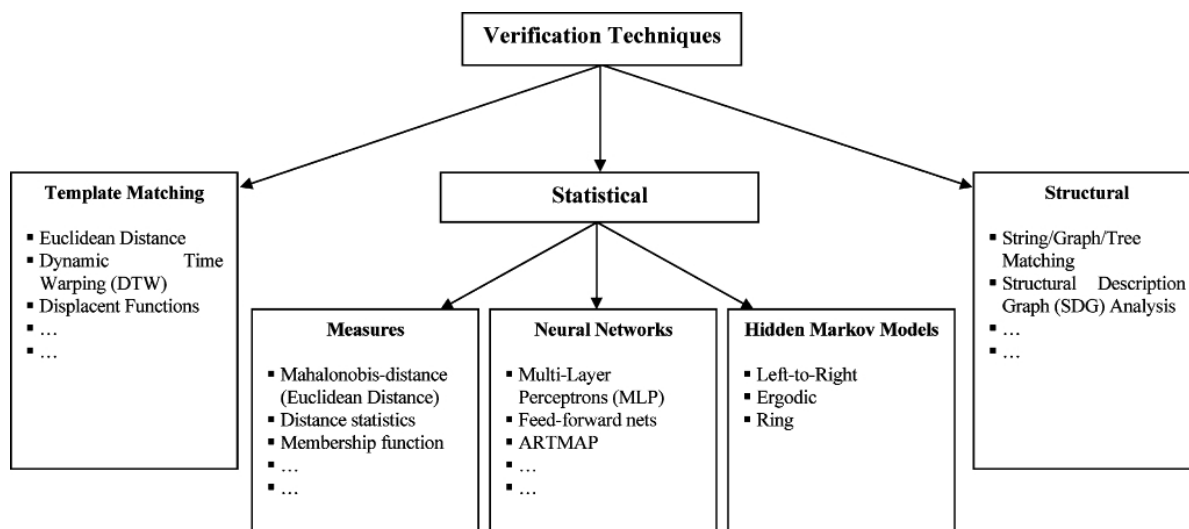
Ostatní parametry uvedené v tabulce III se používají spíše pro statické ověřování podpisu, pokud nejsou k dispozici dynamické informace. Typickými lokálními znaky extrahovanými ze signatury na úrovni komponent jsou například geometrické parametry, jako je plocha obrazu podpisu, výška a šířka podpisu, poměr délky k šířce, poměr šířky střední zóny k šířce podpisu, počet charakteristických bodů (koncové body, křížové body, hroty, smyčky atd.) a podobně [8], [17], [290]. Další známé parametry založené na sklonu [8], [17], [59], [270], [301], orientace [290], obrys [15], [26], [230], [231], [274], směrovost [1], [2], [3], [4], [5], [6], [7], [8].

[66]-[68], [149], [282], [301], [350] a zakřivení [138], [145] byly rovněž zvažovány. Naopak typickými parametry extrahovanými na úrovni pixelů jsou funkce založené na mřížce. Při použití parametrů založených na mřížce se obraz podpisu rozdělí na obdélníkové oblasti a v každé oblasti se vyhodnotí dobře definované charakteristiky obrazu, jako je rozložení inkoustu [17], [301] nebo normalizovaný vektorový úhel [185]. Mřížkové rysy a globální geometrické rysy se používají k vytvoření vícestupňových verifikačních funkcí [263]-[265]. Byly také extrahovány texturní rysy založené na maticích spoluvýskytu signatury [17], tvarových maticích [283] a intenzitních rysech na úrovni šedi, které poskytují užitečné informace o tlaku [44], [126]. Rozšířený stínový kód byl považován za příznakový vektor, který do rozhodnutí o verifikaci zahrnuje jak lokální, tak globální informace [284]. Morfologickým tvarovým deskriptorem používaným při ověřování podpisu je *pecstrum*, které se vypočítá měřením

výsledku postupného morfologického otevírání

TABULKA III
VLASTNOSTI
PARAMETRŮ

Parameters	Category	References
Total signature time duration	Online	R.S.Kashi et al. [146, 147], J.Lee et al. [166], L.L.Lee et al. [169, 170], W.Nelson et al. [227], T.Qu et al. [266], W.S.Wijesoma et al. [335]
Pen-down time ratio	Online	R.S.Kashi et al. [146, 147], W. Nelson et al. [227], W. S. Wijesoma et al. [335]
Number of PenUps/Pen Downs	Online	M.C.Fairhurst and S. Ng [82], G.V. Kiran et al. [158], J. Lee et al. [166], L.L.Lee et al. [169, 170], T. Qu et al. [266]
AVE/ RMS/ MAX/ MIN of Posit., Displ., Speed, Accel.	Online / Offline	R. S. A. Araujo et al [11], M.C.Fairhurst and S. Ng [82], M. Fuentes et al. [104], R.S.Kashi et al. [146, 147], M.A. Khan et al. [154], J. Lee et al. [166], L.L.Lee et al. [169, 170], W. Nelson et al. [227], T. Qu et al. [266], W. S. Wijesoma et al. [335]
Time duration of Positive/Negative Posit., Displ., Speed, Accel.	Online	R. S. A. Araujo et al [11], M.C.Fairhurst and S. Ng [82], R.S.Kashi et al. [146, 147], J. Lee et al. [166], L.L.Lee et al. [169, 170], W. Nelson et al. [227], W. S. Wijesoma et al. [335]
X-Y correlation of Posit., Displ., Speed, Accel.	Online	A.N. Abu-Rezq and A.S. Tolba [2], M. Fuentes et al. [104], R.S.Kashi et al. [146, 147], W. Nelson et al. [227]
Fourier Transform	Online / Offline	G. Congedo et al. [41], G. Dimauro et al. [54, 56, 57, 59], D.K.McCormack et al. [194], Z.-H. Quan et al. [268], C.-J. Wen et al. [332], Q.Z. Wu et al. [345, 347], J. Yi et al. [361]
Hadamard Transform	Offline	W.F. Nemcek and W.C. Lin [228]
Cosine Transform	Online	T. Matsuura and T.S. Yu [193]
Wavelet Transform	Online / Offline	P.S.Deng et al. [49], E.A.Fadhel and P.Bhattacharyya [75, 76], D.Letjman and S.George [176], R.Martens and L.Claesen [189], D.K. McCormack et al. [194], D.K.McCormack and J.F.Pedersen [195], I. Nakanishi et al. [220, 221, 222, 223], V.E.Ramesh and M.Narasimha Murty [274], A. Vergara da Silva and D. Santana de Freitas [323], Z. Yang and C.-C. Jay Kuo [356]
Radom transform	Offline	J. Coetzer et al. [38]
Fractal Transform	Offline	K. Huang and H. Yan [127], S. Mozaffari et al. [206]
Direction-based	Online / Offline	S. Armand et al. [13], N.-J. Cheng et al. [36], J.P.Drouhard et al [66, 67, 68], M.C.Fairhurst and S. Ng [82], K. Huang and H. Yan [128], M. Kalera et al. [145], R.S.Kashi et al. [146, 147, 149], J. Lee et al. [166], H. Lv et al. [184], T. Matsuura and S. Yamamoto [192], W. Nelson et al. [227], Y. Qi and B.R. Hunt [264], T. Qu et al. [266], S.K. Ramanujan et al. [273], R.Sabourin and J.P.Drouhard [282], M. Shridhar et al. [301], S. N. Srihari et al. [307, 308], H. Srinivasan et al. [309, 310, 311], W.S.Wijesoma et al. [335], X.-H. Xiao and G. Leedham [350], L.Yang et al. [357], E.N. Zois et al. [378], M. Zou et al. [379]
Geometric-based	Offline	M. Ammar [8], S. Ando and M. Nakajima [9], H. Baltzakis and N. Papamarkos [17], L. P. Cordella et al. [44], G. Dimauro et al. [59], J.K. Guo et al. [114], K.Han and I.K.Sethi [116, 117, 118], K. Huang and H.Yan [126], Y. Qi and B.R. Hunt [263, 264, 265], V.E.Ramesh and M.Narasimha Murty [274], Y. Xuhua et al. [354], X. Ye et al. [358]
Curvature-based	Online / Offline	A.K. Jain et al. [138], E.J.R. Justino et al. [143], M. Kalera et al. [145], S. N. Srihari et al. [307, 308], H. Srinivasan et al. [309, 310, 311], Y. Xuhua et al. [354]
Structure-based	Offline	G. Dimauro et al. [59], M. Kalera et al. [145], R. Sabourin et al. [290], S. N. Srihari et al. [307, 308], H. Srinivasan et al. [309, 310, 311]
Graphometric-based	Offline	E.J. R. Justino et al. [141, 142, 143, 144], L.S. Oliveira et al. [236], C. Santos et al. [295]
Peripheral-based	Offline	B. Fang and Y.Y. Tang [85]
Projection-based	Offline	A.N. Abu-Rezq and A.S. Tolba [2], R. Bajaj and S. Chaudhury [15], H. Baltzakis and N. Papamarkos [17], G. Dimauro et al. [59], B. Fang et al. [83, 84], Y. Qi and B.R. Hunt [263, 264, 265], C. Quek and R.W.Zhou [270]
Slant-based	Offline	M.Ammar et al. [8], H.Baltzakis and N.Papamarkos [17],G.Dimauro et al. [59], E.J.R.Justino et al. [143],C.Quek and R.W.Zhou [270], M.Shridhar et al. [301]
Orientation-based	Offline	R. Sabourin et al. [280]
Contour-based	Offline	R. Bajaj and S. Chaudhury [15], H. Cardot et al. [26], S. Chen and S. N. Srihari [33], M.A. Ferrer et al. [91], F. Nouboud [230], F. Nouboud and R. Plamondon [231], I. Pavlidis et al. [243], V.E.Ramesh and M.Narasimha Murty [274]
Grid-based	Offline	H. Baltzakis and N. Papamarkos [17], A.El Yacoubi et al. [71], K. Huang and H.Yan [126], V. K. Madasu et al. [185], F. Nouboud and R. Plamondon [231], Y.Y.Qi and B.R. Hunt [263, 264, 265], M. Shridhar et al. [301], C. Simon et al. [302], L. Wan et al. [329], X.-H. Xiao and G. Leedham [350]
Moment-based	Online / Offline	A.N. Abu-Rezq and A.S. Tolba [2], R.C. Doria et al [64], M.C.Fairhurst and S. Ng [82], R.S.Kashi et al. [146, 147], C.-L. Liu et al. [183], H. Lv et al. [184], V.E.Ramesh and M.Narasimha Murty [274]
Texture-based	Offline	H. Baltzakis and N. Papamarkos [17], L. Wan et al. [329]
Shape Matriccs	Offline	R. Sabourin et al. [283]
Gray-level intensity-based	Offline	I. P. Cordella et al. [44], K. Huang and H.Yan [126], H. Lv et al. [184]
Shadow code-based	Offline	F. Nouboud and R. Plamondon [231], R. Sabourin et al. [281, 284, 285], C. Simon et al. [302]
Smoothing-based	Offline	B. Fang et al. [87]
Pattern Spectrum	Offline	R.Sabourin et al. [286, 288]



Obr. 5. Techniky ověřování podpisu.

obrazu, jak se zvětšuje velikost strukturujícího prvku [286]. Takto získané sekvence otvorů se nazývají *granulomy* [288]. Index hladkosti byl použit pro detekci kvalifikovaných padělků při offline ověřování podpisů. Tato technika byla inspirována znalci, kteří vypožadovali, že dobře zfalšované podpisy jsou v detailním měřítku obecně méně hladké než pravé [87]. Podle expertního forenzního přístupu [295], [304] byly zvažovány také grafometrické parametry, včetně statických znaků (kalibr, proporcionálnost atd.) a pseudodynamických znaků (zdánlivý tlak, zakřivení tahu a pravidelnost) [141], [142], [144], [295]. Stojí totiž za zmínku, že výzkum v oblasti automatického ověřování podpisů byl silně ovlivněn prací forenzních examinatorů dokumentů, jak je uvedeno v některých vynikajících pracích [23], [99], [246], [305], [306]. Vycházejíce ze statického obrazu podpisu lze například pomocí pseudodynamických rysů získat informace o dynamice základního procesu podepisování. To je forenzními experty považováno za zásadní aspekt týkající se autorství daného vzorku [99], [101], [304]. Obecně lze říci, že ačkoli ne každý znak analyzovaný soudním znalcem může být snadno reprezentován jako znak parametru extrahovaný počítačovým programem - a *naopak* [246], [305], je poměrně snadné najít úzké vztahy mezi mnoha znaky parametru a některými hlavními znaky používanými soudními znalci [70], [99], [101], [236], [295], [303]-[305].

Ať už se uvažuje o jakémkoli souboru znaků, důkazy o tom, že indi-

viduální podpis je jedinečný, vedlo mnoho výzkumníků k tomu, aby věnovali zvláštní pozornost výběru nejvhodnějších znaků pro podepisující osobu. Podpisy různých pisatelů totiž obecně obsahují jen velmi málo společných znaků, a proto není použití univerzálně použitelného souboru znaků efektivní. Výběr příznaků v oblasti ověřování podpisů je nutný také proto, že efektivita systému, náklady na zpracování a paměťová náročnost jsou přísně závislé na kardinalitě množiny příznaků [77], [80], [152], [276]. Čím menší je tedy vektor příznaků, tím většího počtu osob lze do systému zapsat a tím vyšší rychlosti lze dosáhnout v procesu ověřování [77], [78]. V posledních letech bylo navrženo několik technik pro výběr příznaků na základě

Analýza hlavních komponent (PCA) a samoorganizující se mapy funkcí [317], sekvenční dopředné prohledávání/sekvenční zpětné prohledávání (SFS/SBS) [80], inter-intra class distance radia (ICDR) [82] a analýza variability funkcí [227], [252]. Byla také navržena analýza příznaků založená na padělání, která vybírá sady příznaků vhodné pro náhodné, resp. kvalifikované padělání. Tento přístup byl motivován důkazy, že některé rysy jsou nejvhodnější pro rozlišení kvalifikovaných padělků od pravých podpisů, zatímco jiné rysy jsou lepší pro rozlišení náhodných padělků [275].

Jiné přístupy používají pro každou osobu stejnou sadu rysů a potýkají se s problémem personalizovaného výběru rysů tím, že každému rysu přiřadí jinou váhu [157]. Neuronové sítě (NN) [168] a genetické algoritmy (GA) byly široce používány pro určení geneticky optimalizovaných váhových parametrů [274], stejně jako pro výběr optimálních funkcí [191], personalizovaných parametrů [334], [352]-[354] nebo podpisových tahů, které se mají použít pro ověření [325], [326].

IV. KLASIFIKACE

V procesu ověřování se pravost testovacího znaku vyhodnocuje porovnáním jeho vlastností s vlastnostmi uloženými ve znalostní bázi vytvořené ve fázi zápisu. Výsledkem tohoto procesu je jediná odpověď (logická hodnota), která vyjadřuje pravost testovacího podpisu. Proces ověřování zahrnuje mnoho kritických aspektů, které sahají od techniky porovnávání podpisů až po strategii použitou pro vývoj znalostní báze.

Na obr. 5 jsou uvedeny některé z nejvýznamnějších přístupů k ověřování sig- nality, ačkoli v několika případech lze použít smíšená řešení. Při použití technik porovnávání šablon se zpochybňovaný vzorek porovnává se šablonami pravých/falšovaných podpisů. V tomto případě nejběžnější přístupy používají pro porovnávání podpisů DTW. Při použití statistických postupů lze uvažovat o klasifikátorech založených na vzdálenosti. Pro ověřování podpisů se také hojně používají NN, a to díky jejich schopnostem učení a zobecňování. V poslední době je zvláštní pozornost věnována použití skrytých Markovových algoritmů.

modelů (HMM) pro offline i online ověřování podpisů. Syntaktické přístupy se obecně týkají strukturálních reprezentací podpisů, které jsou popsány prostřednictvím svých elementárních prvků (nazývaných také "primitiva") a porovnávány pomocí technik porovnávání grafů nebo tří.

Klasifikační techniky, které se v literatuře nejčastěji používají, jsou uvedeny v tabulce IV. Uvažujeme-li funkce, může být problém přiřazování komplikován náhodnými odchylkami, způsobenými pauzami nebo zaváháním pisatele. Tyto odchylky mohou vytvářet části signálů, jako jsou vynechávky, doplňky a mezery, které problém přiřazování komplikují. DTW al- lows komprese nebo expanze časové osy dvou časových posloupností reprezentujících podpisy s cílem získat minimum dané hodnoty vzdálenosti [32], [177], [339], [363], [366], [373]. Přesněji řečeno, nechť $T : (T_1, T_2, \dots, T_{N_T})$ a

$R : (R_1, R_2, \dots, R_{N_R})$ jsou dva online podpisy, DTW se používá k určení optimální deformační funkce $W^*(T, R)$, která minimalizuje dobře definovanou míru nepodobnosti $DW(T, R) =$

$$\sum_{k=1}^K d(c_k), \text{ kde } c_k = (i_k, j_k) \text{ (} k, i_k, j_k \text{ celá čísla, } 1 \leq k \leq K, 1 \leq i_k \leq N_T, 1 \leq j_k \leq N_R \text{) a } d(c_k) = d(T_{i_k}, R_{j_k})$$

je míra vzdálenosti mezi vzorky T a R . Podrobná diskuse o DTW, která byla původně použita v oblasti zpracování řeči, přesahuje cíl tohoto článku a další informace lze nalézt v literatuře [272].

Ačkoli v oblasti automatického ověřování podpisů nebyla prokázána nadřazenost DTW vůči jiným srovnávacím technikám, jako je regionální korelace a porovnávání skeletových stromů [241], [249], DTW se hojně používá a byly zkoumány kontinuální [207]-[209] a paralelní [14] implementace. Kromě toho bylo použito několik technik pro signální redukci dat založených na GA [337], [338], PCA [155], [180], analýze menších komponent (MCA) [180], lineární regresi (LR) [175], polygonální aproximaci (PA) [337], [338],

extrémní body (EP) [90] a náhodný výběr [337], [338]. Zkoumal se také DTW založený na tazích [339]. Tento postup vychází z úvahy, že porovnávání kompletních časových posloupností povede nejen k vyššímu výpočetnímu zatížení, ale také ke ztrátě informací souvisejících se strukturní organizací signatur. Aby se zabránilo deformaci referenčních signálů při porovnávání se zkušebními vzorky, byla definována dobře vyhovující forma asymetrického DTW [186], [187], [189]. Další přístupy k porovnávání šablon mohou využívat dobře definované míry deformace [344], míry podobnosti [347], funkce posunutí [199], [200], relaxační porovnávání [128], kumulované postupové a rychlostní vzdálenosti založené na mechanismech rozdělení a sloučení [346], fuzzy logiku [185] a porovnávání vzorů [283], [318].

Při použití parametrů jako rysů se obvykle volí techniky založené na statistice. Nejčastěji se používají Mahalanobisovy a Euklidovy vzdálenosti: Mahalanobisova vzdálenost se používá, pokud je k dispozici úplná kovarianční matice pro každou třídu signatur [85], [186], [188], [189], [268], [371]; Euclidean distance se uvažuje, pokud je znám pouze střední vektor třídy [54], [56], [57], [273], [288], [295]. Členství byly použity také funkce [266] a další statistiky vzdáleností [145], [310].

některé z modelů NN, které byly v poslední době použity: [30], [351], vícevrstvé perceptrony (MLP) [7], [15], [17], [126], [167], [345], [350], NN s časovým zpožděním [22], [167],

ARTMAP NN [215]-[217], zpětně se šířící neuronové sítě (BPN) [13], [15], [47], [66]-[68], samoorganizující se mapy [1], [2],

a radiální báze funkce (RBF) [13], [109], [203], [232], [316]. Uvažuje se také o fuzzy NN, které kombinují výhody NN i systémů založených na fuzzy pravidlech [102], [270], [353]. Za účelem zvýšení efektivity při použití NN byly navrženy a pro vstupy použity vhodné transformované verze signatur [37]. Jedna transformace může reprodukovat vzor časové řady za předpokladu konstantní lineární rychlosti a modelovat tak tempové charakteristiky procesu podepisování; jiná transformace může mapovat signál na rovinu horizontální versus vertikální rychlosti, kde je změna rychlosti v čase reprezentována jako viditelný tvar. Jiné přístupy místo toho nejprve upraví testovací signál na signaturu šablony pomocí dynamického programování (DP) a poté pomocí NN porovnávají dynamické informace

podél shodných bodů signatur [316]. Ačkoli NN

NN se již dlouho hojně používají pro automatické ověřování podpisů, jak ukazuje [165]. Tabulka IV ukazuje

prokázaly dobrou schopnost generalizace [75], vyžadují však velké množství učebních dat, která nejsou vždy k dispozici [156]. Za tímto účelem bylo navrženo také použití synteticky generovaných signatur [126].

V poslední době se HMM věnuje intenzivní výzkum. Tyto modely se ukázaly jako vhodné pro modelování podpisů, protože jsou velmi dobře přizpůsobitelné osobní variabilitě [104], [190], [321], [357]. Přísně vzato je HMM dvojí stochastický přístup, v němž lze jeden základní, avšak neobsluhovatelný proces odhadnout prostřednictvím souboru procesů, které vytvářejí posloupnost pozorování. Komplexní diskuse o HMM přesahuje cíl tohoto článku a lze ji nalézt v literatuře [271]. Co se týče oblasti ověřování podpisů, byly dosud zvažovány různé topologie HMM, jak ukazuje obr. 6. Na obr. 6 je vidět, že HMM jsou v tomto ohledu nejčastěji používány v praxi. Většina přístupů používá topologii HMM zleva doprava, protože je považována za vhodnou pro modelování podpisu [71], [91], [130], [146], [321], [333], [379]. Ergodická topologie


byla rovněž zvažována pro online i offline ověřování podpisů [269], [333]. Navíc, aby byla zaručena invariance vůči rotaci podpisu, byla přijata kruhová topologie, která je ekvivalentní topologii zleva doprava a je povolen přechod z posledního stavu do prvního stavu [38]. Nicméně nezávisle na použité topologii se zdá, že HMM jsou lepší než jiné techniky modelování signatur založené na strukturálních popisech [128], [129] a fuzzy přístupech [119], [185]. Některé výsledky také ukázaly, že systémy založené na HMM pro offline ověřování signatur mohou překonat lidské ověřovatele [39]. Nejnovější přístupy navíc používají HMM v kombinaci s autoregresivními modely, zatímco podpis je rozložen na pseudostacionární segmenty a reprezentován jednorozměrnou prostorovou stochastickou posloupností [202]. Zkoumán byl také vliv interpersonální a intrapersonální variability na HMM [141], stejně jako možnost automatického a dynamického odvození různých parametrů závislých na autorovi pomocí *křížové validace* [71].

Další slibnou metodou jsou podpůrné vektorové stroje (SVM).

tický přístup k ověřování podpisů. SVM je nová klasifikační technika v oblasti teorie statistického učení a byla úspěšně použita v mnoha aplikacích rozpoznávání vzorů. SVM dokáže mapovat vstupní vektory do vyššího dimenzionálního prostoru, v němž mohou být shluky určeny maximem

TABULKA IV
SROVNÁVACÍ TECHNIKY

Technique		Category	References
Euclidean Distance		Online / Offline	R. S. A. Araujo et al. [11], G. Dimauro et al. [54, 56, 57], M.A. Ferrer et al. [91], M.A. Khan et al. [154], S. Ramanujan et al. [273], R. Sabourin et al. [288], C. Santos et al. [295], L. Wan et al. [329]
Mahalanobis Distance		Online / Offline	B. Fang et al. [85], S. Krawczyk and A. K. Jain [160], R. Martens and L. Claesen [186, 188, 189], Z.-H. Quan et al. [268], K. Zhang et al. [371]
Pattern Matching		Offline	C.-C. Lien et al. [181], R. Sabourin et al. [283], K. Ueda [318]
Membership functions		Online	T. Qu et al. [266]
Distance Statistics		Offline	M. Kalera et al. [145], H. Srinivasan et al. [310]
Dynamic Similarity Measure		Online	Q. Z. Wu et al. [347]
Dynamic Time Warping (DTW)	Continuous	Online	L. Bovino et al. [18], Y.Chen and X.Ding [32], G. Congedo et al. [40], V. Di Lecce et al. [50, 51], G. Dimauro et al. [53, 55, 59], K. Huang and H. Yan [129], J.P. Leszczyska [177], M.E. Munich and P. Perona [207, 208, 209], I.Yoshimura and M. Yoshimura [363], M. Yoshimura et al. [366]
	Parallel	Online	Y.J. Bae and M.C. Fairhurst [14]
	GA-based	Online	M. Wirotius et al. [337, 338]
	PCA-based	Online	A. Kholmatov and B. Yanikoglu [155], B.Li et al. [180]
	MCA-based	Online	B.Li et al. [180]
	LR-based	Online	H. Lei et al. [175]
	PA-based	Online	M. Wirotius et al. [337, 338]
	EP-based	Online	H. Feng and C.C. Wah [90]
	Random-based	Online	M. Wirotius et al. [337, 338]
	Stoke-based	Online	B. Wirtz [339]
	Asymmetric	Online	R. Martens and L.Claesen [186, 187, 189]
Dynamic Programming		Online / Offline	B. Fang et al. [83, 84], J. K. Guo et al. [114], J. Lee et al. [166], I. Nakanishi et al. [220], F. Nouboud [230], F. Nouboud and R. Plamondon [231]
Correlation		Online	J.B.Fasquel, M.Bruynooghe [88], K.K. Lau et al. [163], J.S. Lew [179], M.L. Molina et al. [204], V. S. Nalwa [224], M. Perizeau and R. Plamondon [241], C.-J. Wen et al. [332]
Relaxation Matching		Offline	K. Huang and H. Yan [128], C.-F. Lin and C.-W. Chen [182]
Bayesian approach		Offline	D. Muramatsu et al. [212]
Split-and-Merge		Online	Q.Z. Wu et al. [346]
String / Graph / Tree Matching		Online / Offline	Y. Chen and X. Ding [31], S. Chen and S. N. Srihari [33, 34, 35], N.-J. Cheng et al. [36], K. Han and I. K. Sethi [118], A. K. Jain et al. [138], I. Pavlidis et al. [243, 244], M. Perizeau and R. Plamondon [241], X.-H. Xiao and R.W. Dai [349]
Structural Description Graph		Online/Offline	L. Bovino et al. [18], G. Dimauro et al. [56], K. Huang and H.Yan [129]
Displacement Function		Offline	Y. Mizukami et al. [199, 200]
Fuzzy Logic		Offline	M. Hanmandlu et al. [120], V. K. Madasu et al. [185], W. S. Wijesoma et al. [335], K. Zhang et al. [372]
Support Vector Machine (SVM)		Online / Offline	M.A. Ferrer et al. [91], M. Fuentes et al. [104], E. J.R. Justino et al. [143], A. Kholmatov and B. Yanikoglu [155], H. Lv et al. [184], S.N. Srihari et al. [308]
Neural Network (NN)	Bayesian	Online / Offline	H.D.Chang et al. [30], X.-H.Xiao and G. Leedham [351]
	Multi-Layer Perceptrons (MLP)	Online / Offline	A. I. Al-Shoshani [7], R. Bajaj and S. Chaudhury [15], H. Baltzakis and N. Papamarkos [17], H. Cardot et al. [26, 27], L.P. Cordella et al. [44, 45], E. A. Fadhel and P. Bhattacharyya [75], M. Fuentes et al. [104], K.Huang et al. [123, 124, 125, 126], L. L. Lee [168], W.-S. Lee et al. [172], C. Sansone and M. Vento [294], C. Santos et al. [295], Q.-Z. Wu et al. [343, 344], X.-H. Xiao and G. Leedham [350]
	Time-Delay	Online / Offline	J. Bromely et al. [22], I. L. Lee [167]
	ARTMAP	Online / Offline	N.A. Murshed et al. [215, 216, 217, 199]
	Backpropagation Network (BPN)	Online / Offline	S. Armand et al. [13], R. Bajaj and S. Chaudhury [15], A.M. Darwish and G.A. Auda [47], J.P.Drouhard et al. [66, 67, 68], D.Z. Letjman and S.E. George [176], N.A. Murshed et al. [218], R. Sabourin and J.P. Drouhard [282]
	Self-organizing Map	Online / Offline	A. Abu-Rezq and A.S. Tolba [1, 2], H. Cardot et al. [26, 27], A.S. Tolba [317], T. Wessels and C.W. Omlin [333]
	Fuzzy Nets	Online / Offline	K. Franke et al. [102], C. Quek and R.W.Zhou [270], S. Watanabe et al. [330, 331], Y. Xuhua et al. [353, 354]
Hidden Markov Models (HMM)	Radial Basis Functions (RBF)	Online / Offline	S. Armand et al. [13], H. Baltzakis and N. Papamarkos [17], C. Gruber et al. [109], M.L. Molina et al. [203], N. F. O'Brien and S. C. Gustafson [232], M. Tanaka et al. [316]
	Left-to-right topology	Online / Offline	J.G.A. Dolfing et al. [63], A. El-Yacoubi et al. [71], M.A. Ferrer et al. [91], J. Fierrez-Aguilar et al. [94, 96, 97], M. Fuentes et al. [104], J. J. Igarza et al. [130, 131], E.J.R. Justino et al. [141, 142, 143], R.S. Kashi et al. [146, 147], D.Muramatsu and T.Matsumoto, [213, 214], J. Ortega-Garcia et al. [238], S.K. Ramanujan et al. [273], G.Rigoll and A. Kosmala [277], M.M.Shafiei and H.R. Rabiee [299], B. Van et al. [321], T. Wessels and C.W. Omlin [333], I. Yang et al. [357], H.S. Yoon et al. [362], M. Zou et al. [379]
	Ergodic topology	Online / Offline	Z. -H. Quan and K.-H. Liu [269], T. Wessels and C.W. Omlin [333]
	Ring topology	Offline	J. Coetzer et al. [38]



Obr. 6. Topologie HMM. (a) Zleva doprava. (b) Ergodická. (c) Prstencová.

separační hyperplochu [25]. SVM byly úspěšně použity jak v offline [91], [143], [184], tak v online [104], [155] ověřování signálů.

Strukturální přístupy se týkají především technik porovnávání řetězců, grafů a stromů a obvykle se používají v kombinaci s jinými technikami. Například porovnávání řetězců [31], [349] se používá nejen pro účely ověřování podpisů, ale také pro účely identifikace podpisů prostřednictvím pokročilého lokálního asociativního indexování [118]. V jiných případech se *graf strukturního popisu* používá k ověření strukturní organizace zpochybňovaného podpisu [18], [56], [129], jak ukazuje obr. 7.

V posledních letech se zkoumají víceexpertní přístupy (ME), které mají zlepšit výkonnost ověřování podpisů. K tomuto účelu byly použity sériové [55], [161], [294], [371], paralelní [59], [265] nebo hybridní strategie [44], [45] a byly přijaty dobře definované techniky pro odhad spolehlivosti [43]. Mezi ostatními se hybridní kombinační strategie zdají být zvláště vhodné pro ověřování podpisů, protože se snaží dosáhnout výkonnostních výhod sériových přístupů při rychlém odmítání velmi špatných padělků a zároveň zachovat spolehlivost paralelních kombinačních schémat [44], [45].

Vzhledem k tomu, že systém ověřování ME by měl kombinovat rozhodnutí doplňujících se ověřovatelů podpisu, byly použity sady ověřovatelů založené na globálních a lokálních strategiích [92], [95] a sady funkcí [123], [125], funkce parametrů a funkce [260], statické a dynamické funkce [50], [51]. Bylo implementováno několik schémat kombinace rozhodnutí, od většinového hlasování [4], [50], [51], [59], [274] až po Borda count [12], od jednoduchého a váženého průměrování [18] až po Dempster-Shaferovu teorii důkazů [12] a NN [15], [17], [26]. Boostovací algoritmus byl použit k trénování a integraci různých klasifikátorů, a to jak pro ověřování online [122], tak offline [329] podpisů. Kromě toho byly přístupy ME použity pro ověřování podpisů na základě tahu, kdy se ověření podpisu provádí analýzou jeho prvků.

Ověřování podpisu na základě tahu může vést k nižší chybovosti ve srovnání s globálními přístupy, protože velké množství osobních informací je obsaženo v určitých částech podpisu a nelze je odhalit, pokud se na podpis pohlíží jako na celek [8], [21], [54]–[57], [59], [126], [164], [278], [298].

Kromě toho je ověření při mrtvici může být provedena pomocí DTW [41], [50], [51], [55], také

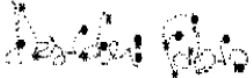

















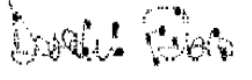






zohlednění více funkčních prvků pro zobrazení mrtvice

(jako je poloha, rychlost a zrychlení), aby bylo možné ověřit tvar i dynamiku každé části signatury [18].

Vedle technik porovnávání byla věnována pozornost rozvoji znalostní báze také v souvislosti se strategiemi učení [308], [310], [311] a technikami modelování signatur [248], [308]. Zvláštní pozornost byla věnována zejména strategiím učení závislým na pisateli, které využívají pouze genové vzorky [156], [215], [216], [217], [328]. V tomto případě první přístup využívá jediný prototyp pravých podpisů pro každého pisatele a pro vývoj optimálního průměrného prototypu pro podepisujícího bylo navrženo několik technik, včetně kombinace tvaru a dynamických rysů [298], průměrování na základě času a polohy [340] nebo výběru gen- uiného vzorku s nejmenším průměrným rozdílem, pokud je porovnáván s ostatními dostupnými pravými podpisy [156]. Po určení prototypu je rozhodovací práh gen- erálně definován na základě hodnot rozdílů, které lze určit z pravých signatur [156]. Druhý přístup používá jako referenci sadu pravých signatur. V tomto případě se zásadní problém týká výběru optimální podmnožiny referenčních podpisů z dostupných vzorů. Při statickém ověřování podpisů byla platnost referenčního modelu hodnocena podle specifických kritérií kvality, jako je například vnitrotřídní variabilita, která by měla být co nejnižší [3], [78], [79]. Při dynamickém ověřování signatur se výběr nejlepší podmnožiny referenčních signatur prováděl na základě analýzy rozptylu v rámci vzorků [112] nebo s přihlédnutím k oblastem stability v signaturách,


určeným na základě dobře definované analýzy lokální stability [40], [51]. Výběru nejlepší podmnožiny referenčních signatur se lze vyhnout i za cenu použití vícenásobných modelů pro ověřování signatur [148], [197], [198]. Navíc vývoj znalostní báze zahrnuje problém nedostatku dostatečného množství referenčních dat pro charakterizaci dané třídy signatur, což je obecně případ mnoha praktických aplikací. Proto se specifický výzkum věnuje modelování znaků [158], [279], a to i s využitím regularizačních technik, které odhadují statistickou významnost tréninkových souborů malých rozměrů [85], [86], [276]. Jiné přístupy navrhuji generování dodatečných trénovacích vzorků z těch stávajících pomocí konvolací [48], pružného porovnávání [85], [86] a perturbací [126]. A konečně, slibný výzkum byl v poslední době věnován zkoumání různých typů, složitosti a stability signatur. Tyto aspekty mají velký teoretický i praktický význam, protože zdůrazňují velký rozdíl mezi lidmi a stroji při vnímání, zpracování a ověřování signatur a zároveň poskytují základní informace pro vývoj systémů nové generace s vysokými adaptivními schopnostmi. Například krátké podpisy mohou předávat méně informací než dlouhé podpisy, což vede k méně přesným výsledkům ověřování [20]. Podobně by lidé se společnými jmény mohli s větší pravděpodobností sdílet podobné podpisy s jinými jedinci - alespoň co se týče tvarových charakteristik. V obou případech by měl být systém schopen přizpůsobit se charakteristikám osob, které se v něm vyskytují. zařazených osob [278].

Složitost podpisu byla kvantifikována pomocí odhadu obtížnosti jeho napodobení, který byl získán jako výsledek odhadované obtížnosti vnímání, přípravy a provedení každého tahu samotného podpisu [20].

Authentic Signatures		Fundamental Components								
		a	b	c	d	e	f	g	h	i
S^1										
S^2										
S^3										

(a)

$S^1 = ("a", "b", "c", "d", "e", "f", "g", "h", "i"); S^2 = ("ab", "cd", "e", "f", "g", "h", "i"); S^3 = ("abc", "d", "e", "f", "g", "h", "i")$



(b)

Obr. 7. Strukturní popis signatur. (a) Popis autentických podpisů podle komponent. (b) Graf strukturního popisu.

Pokud jde o stabilitu podpisu, lze pomocí DTW získat funkci lokální stability pro porovnání pravého podpisu s jinými autentickými vzorky [42], [53], [129]. Při každé shodě se identifikují *bodů přímé shody* (DMP), což jsou jednoznačně shodné body pravého podpisu. DMP tak mohou indikovat přítomnost malé stabilní oblasti podpisu, protože nebylo lokálně zjištěno žádné významné zkreslení. Formálněji řečeno, nechť $T: (T_1, T_2, \dots, T_{N_T})$ je pravý podpis a $R^i: (R^i_1, R^i_2, \dots, R^i_{N_{R_i}})$, $i = 1, 2, \dots, n$ je množina n dalších pravých vzorků. Pro každý pár (T, R^i) , $i = 1, 2, \dots, n$, lze pomocí DTW určit optimální deformační funkci $W^*(T, R^i)$. Z $W^*(T, R^i)$ jsou DMP T vzhledem k R^i identifikovány jako body T , které mají vazbu jedna ku jedné s bodem R^i . Jinými slovy, nechť T_p je bod T spojený s R^i ; T_p je DMP T vzhledem k R^i tehdy a jen tehdy, když:

- 1) $\forall p = 1, \dots, N_T, p \neq p$, vyplývá, že T_p není spojen s R^i ;
- 2) $\forall q = 1, \dots, N_{R_i}, q \neq q$, vyplývá, že R^i není spájený s T_p .

DMP označuje existenci malé části signatury T , která je zhruba podobná odpovídající části signatury R^i , v oblasti určené vzdáleností použitou pro DTW. Proto se pro každý vzorek T zavádí skóre podle typu jeho spojení vzhledem k bodům R^i [42], [53]: Skóre ^{i} (T_p) = 1, pokud je T_p DMP; skóre ^{i} (T_p) = 0, jinak. Lokální funkce stability T je definována jako $I(T_p) = \frac{1}{n} \sum_{i=1}^n \text{Skóre}^i(T_p)$, $p = 1, 2, \dots, N_T$; proto $I(T_p) \in [0, 1]$, $p = 1, 2, \dots, n$. Na obr. 8 je schematicky znázorněn jednoduchý příklad, v němž se lokální stabilita krátké posloupnosti T vyhodnocuje tak, že se uvažují odpovídající posloupnosti S^i , $i = 1, 2, 3$.


Po tomto postupu je na obr. 9 znázorněna analýza stability pro celou testovací signaturu [viz obr. 9a] a identifikace oblastí s nízkou a vysokou stabilitou. Přesněji řečeno, na základě úvahy, že hodnota lokální stability se může pohybovat v rozmezí $[0, 1]$, jsou oblasti s nízkou stabilitou identifikovány jako ty, v nichž je hodnota lokální stability nižší než 0,5, zatímco oblasti s vysokou stabilitou jsou identifikovány jako ty, v nichž je hodnota lokální stability vyšší nebo rovna 0,5 [viz obr. 9b].

Pokud se navíc analýza lokální stability používá k měření krátkodobých modifikací - které závisí na psychickém stavu pisatele a na podmínkách psaní - umožňuje vybrat nejlepší podmnožinu referenčních podpisů [40], [51] a nejefektivnější funkce rysů pro účely ověřování [51] a zároveň poskytuje užitečné informace pro vážení rozhodnutí o ověření získaných na úrovni tahu podle analýzy lokální stability [53], [129]. Dlouhodobé modifikace závisí na změně fyzického systému psaní podepisující osoby (paže a ruky atd.) a také na modifikaci motorického programu v jejím mozku. Při vyhodnocování těchto modifikací lze získat užitečné informace pro aktualizaci referenčního podpisového modelu zahrnutím doplňujících informací z dalších nových podpisů, jakmile budou k dispozici [278].

Jiné typy přístupů odhadují stabilitu souboru společných znaků a fyzikálních charakteristik signatur, s nimiž jsou nejvíce spřízněny, aby bylo možné získat globální informace o opakovatelnosti signatur, které mohou

být použity ke zlepšení verifikačních systémů [110], [111],

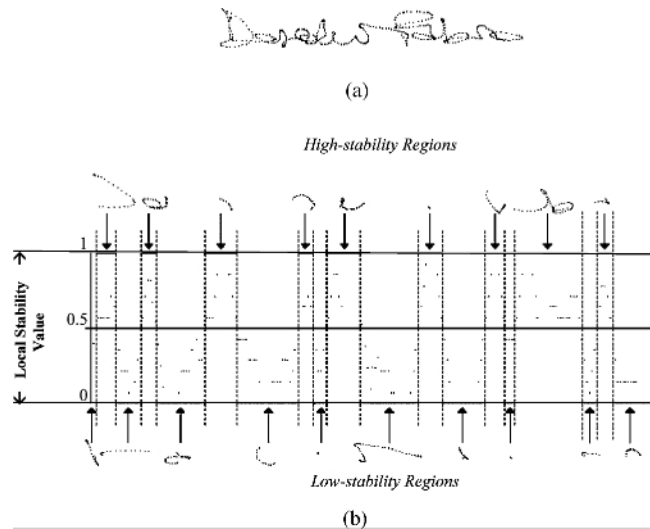
[150]. Obecně tyto přístupy ukázaly, že existuje soubor znaků, které zůstávají dlouhodobě stabilní, zatímco jiné znaky se v čase výrazně mění v závislosti na věku podepisující osoby. To je případ rysů



	Scores									
	T_1	T_2	T_3	T_4	T_5	T_6	T_7	T_8	T_9	T_{10}
$\text{Score}^1(\cdot)$	1	0	1	1	1	1	1	0	0	0
$\text{Score}^2(\cdot)$	0	1	1	1	1	0	1	0	0	0
$\text{Score}^3(\cdot)$	1	1	1	1	1	1	1	1	0	0
Local Stability Value	0.67	0.67	1	1	1	0.67	1	0.33	0	0

(d)


Obr. 8. Vyhodnocení lokální stability. (a) Shoda T versus S^1 a DMP. (b) Shoda T versus S^2 a DMP. (c) Shoda T versus S^3 a DMP. (d) Výpočet lokální stability.



Obr. 9. Analýza lokální stability. (a) Testovací signatura. (b) Oblasti s nízkou a vysokou stabilitou.

související s celkovou dobou provádění, rychlostí a zrychlením [110]. Protože variabilita mezi jednotlivými sezeními je jednou z nejdůležitějších příčin zhoršení výkonosti ověřování, uvažuje se o specifických přístupech k aktualizaci parametrů [150].

Obrovské rozdíly v podpisech lidí z různých zemí si rovněž vyžádaly vývoj speciálně navržených řešení. Například okcidentální styl



Obr. 10. Výkonnostní opatření. (a) FAR a FRR. (b) Graf ROC.

Podpisy se obecně skládají ze znaků, které by mohly tvořit zhuštěný text kombinovaný s obrazovými tahy. V některých zemích je zvykem podepisovat se čitelným psaným jménem, zatímco v jiných zemích nejsou podpisy vždy čitelné. Mnohem více rozdílů lze očekávat při posuzování podpisů psaných lidmi z nezápadních zemí. Za tímto účelem byly v literatuře navrženy specifické přístupy pro Číňany [30], [36], [163], [182]–[184], [349] a Japonce [318], [364], [365], [367] podpisy, které se mohou skládat z nezávislých podpisů.

dent symboly, stejně jako arabské/perské [28], [29], [47], [134] podpisy, což jsou kurzivní náčrty obvykle nezávislé na jménu osoby. Obecně lze říci, že s rostoucí potřebou mezikulturních aplikací je stále důležitější vyhodnocovat jak míru vlivu osobního původu na charakteristiky podpisu, tak přesnost procesu verifikace. Za tímto účelem se uvažuje o souboru metadat, který se někdy také nazývá "měkká biometrie". Metadata se týkají

různé aspekty spisovatelova původu, jako je národnost, jazyk písma, věk, pohlaví, rukopis atd. Některá metadata lze odhadnout statistickou analýzou lidského rukopisu, a proto je možné algoritmy pro ověřování podpisů přizpůsobit kontextu metadat s cílem zlepšit výsledky ověřování [140], [297], [326], [342].

V. HODNOCENÍ VÝKONU

Automatické ověřování podpisu může způsobit dva typy chyb: Chyby typu I se týkají falešného odmítnutí pravých podpisů [míra falešného odmítnutí (FRR)]; chyby typu II se týkají falešného přijetí padělaných podpisů [míra falešného přijetí (FAR)]. Proto se výkonnost systému pro ověřování podpisů obecně odhaduje z hlediska FRR a FAR [165], [248], [258]. V závislosti na aplikacích je třeba definovat kompromis mezi oběma typy chyb, protože každé snížení FAR zvyšuje FRR a *naopak*. Kromě toho je za míru celkové chybovosti systému všeobecně považována rovnoměrná chybovost (EER), která je definována jako chybovost systému, kdy $FRR = FAR$ [viz obr. 10(a)] [341]. V ostatních případech se používá celková chybovost ϵ_t , která je definována jako $\epsilon_t = ((FRR - P(\omega_1)) + (FAR - P(\omega_2)))$ - kde $P(\omega_1)$ a $P(\omega_2)$ jsou *apriorní* pravděpodobnosti tříd pravých podpisů (ω_1) a padělků (ω_2) [281]- [283]. Pro hodnocení FRR versus FAR se také používá analýza křivky ROC (receiver operating characteristic), protože ukazuje schopnost systému rozlišit pravé podpisy od padělaných [viz obr. 10b)] [309], [311].

Bohužel, existence kvalifikovaných padělků pro danou podpisu není jistá, stejně jako možnost získat kvalitní vzorky padělků pro test [201], [248]. Protože padělky podpisů jsou výsledkem behaviorální činnosti, jsou silně závislé na typu a množství informací poskytnutých padělateli, stejně jako na jeho tréninku a úsilí [16]. Vyhodnocení FAR je tedy obtížné a obecně nepřesné [259], [377]. Tradiční metoda řešení tohoto problému spočívá v uvažování různých tříd padělků [248]: *náhodné* padělky, při nichž padělatel používá svůj vlastní podpis namísto testovaného podpisu; *jednoduché* padělky, při nichž se padělatel nesnaží pravý podpis napodobit nebo vystopovat; a padělky *z volné ruky* nebo *kvalifikované* padělky, při nichž se padělatel snaží a cvičí v co nejvěrnějším napodobování statických a dynamických informací pravého podpisu. Jiný pokus o třídění kvality padělků uvažuje o následujících čtyřech kategoriích: [377]: *náhodné* padělky jsou ty, které používají libovolné neautentické vzorky písma proti nějaké jiné referenci; *slepi* útočníci jsou ti, kdy padělatel má pouze textovou znalost obsahu písma; padělky *s nízkou silou* se vyskytují, když má padělatel k dispozici offline reprezentaci obrazu podpisu; a *brutální* útočníci jsou ti, kdy má padělatel také možnost pozorovat dynamiku procesu psaní.

V tabulkách V a VI jsou shrnuty charakteristiky některých z nich.

nejzajímavější systémy ověřování podpisů uvedené v literatuře pro offline a online podpisy. U každého systému jsou v následujícím textu stručně popsány některé další informace. Podrobnější popis lze nalézt v literatuře.

V tabulce V Abu-Rezq a Tolba [2] použili neuronový přístup k ověřování podpisů založený na momentově invariantních příznacích a příznacích založených na projekci. Bajaj a Chaudhury [15] použili tzv.

různé typy globálních prvků: na základě projekce (horizontální a vertikální projekce) a na základě obrysu (horní a dolní obálka). Klasifikace byla provedena pomocí napájecích NN klasifikátorů, zatímco klasifikační rozhodnutí byla kombinována pomocí jednoduché vrstvy napájecího NN (ADALINE). Systém Baltzakise a Papamarkose [17] prováděl verifikaci podpisu pomocí globálních, mřížkových a texturních rysů. V tomto případě se klasifikační fáze skládala z dvoustupňového neuronového schématu založeného na RBF. Hybridní schéma ME navržené Cordellou a *spol.* v [44] bylo založeno na dvoustupňových kaskádových klasifikátorech. V prvním stupni používalo rysy založené na obrysech a ve druhém na úrovni šedi, přičemž klasifikace byla v každém stupni prováděna pomocí MLP. V přístupu Deng *et al.* s více rozlišeními [49] byla data o zakřivení rozložena na signály pomocí waveletových transformací. Statistické měření bylo použito k systematickému rozhodnutí, které uzavřené obrysy a s nimi spojené frekvenční údaje spisovatele jsou nejstabilnější a nejlépe diskriminující. Na základě těchto údajů byla vypočtena optimální prahová hodnota, která řídí přesnost procesu extrakce příznaků. V systému ME Dimaura a *kol.* byly použity rysy založené na projekci, šikmosti a geometrii a Granlundovy deskriptory (odvozené pomocí Fourierovy transformace) [59]. Tento systém kombinoval wholistický přístup založený na klasifikátoru euklidovské vzdálenosti, přístup založený na struktuře a přístup založený na NN s využitím NN ARTMAP. Výsledky těchto tří přístupů byly kombinovány pomocí hlasovací strategie. Drouhard a *kol.* v *práci* [68] použili směrovou funkci hustoty pravděpodobnosti (pdf) jako globální tvarový faktor a klasifikátor BPN pro ověřování podpisů. Některé experimentální důkazy ukázaly, že BPN může poskytnout téměř stejný výkon jako klasifikátor k-nejbližšího souseda a je rozhodně lepší než prahový klasifikátor. V přístupu El-Yacoubiho a *dalších* [71] byla pro modelování offline podpisů pomocí HMM-LR uvažována hustota pixelů. Pro každého pisatele uvažovaného ve fázi zápisu byly dynamicky a automaticky odvozeny prahové hodnoty závislé na podepisující osobě. Pro redukci dat i výběr příznaků použili Fadhel a Bhattacharyya [76] wavelety. Navržený systém používal globální (na bázi waveletů), statistické a geometrické rysy a prováděl ověřování podpisů pomocí feedforward NN. Fang a *spol.* v *práci* [84] použili pro porovnávání podpisů rysy založené na vertikální projekci a DTW. Fang a Tang [85] zvažoval soubor periferních rysů a Mahalanobis-prahový klasifikátor založený na vzdálenosti. Navrhli dvě metody, jak čelit problému řídkých dat při offline ověřování podpisu. První z nich uměle generuje další trénovací vzorky ze stávající trénovací sady pomocí techniky pružného porovnávání. Druhý přístup použil regularizační techniku na kovarianční matici vzorků. Experimentální výsledky ukázaly, že obě techniky mohou výrazně zlepšit výkonnost ověřování. Geometrické rysy extrahované z analýzy obrysů a tahů použili Ferrer *et al* [91]. Pro verifikaci náhodných i jednoduchých padělků byly rovněž zvažovány klasifikátor euklidovské distance, SVM a HMM-LR. Experimentální výsledky ukázaly nadřazenost HMM vůči klasifikátorům SVM a Euklidovské vzdálenosti. Huang a Yan [126] představili systém založený na geometrických rysech extrahovaných z různých měřítek. Celkové hodnocení shody bylo generováno kombinací rozhodnutí dosažených v jednotlivých měřítkách pomocí MLP. Statistické modely Huanga a Yana [128] byly

konstruovány pro distribuci pixelů a strukturální popis. Oba geometrické

TABULKA V
VÝKONY: OFFLINE SYSTÉMY

Authors	Main features	Database	Approach	Results
A. N. Abu-Rezq and A. S. Tolba [2]	X-Y correlations, Projection-based, Moment-based	Training 100 (G) (10(G)x10(A)) Test 60 (G) (6(G) x 10(A))	NN	FRR : 3% (FAR : not estimated)
R. Bajaj and S. Chaudhury [15]	Projection based, Contour based (envelope)	Test 150 (G), 100 (F)	NN	FRR : 1%, FAR : 3%
H. Baltzakis and N. Papamarkos [17]	Geometric-based, projection-based, slant-based, grid-based, texture-based	Training 1500 (S) (from 115(A)) Test 500 (S)	NN (RBF)	FRR : 3%, FAR : 9,81%
L. P. Cordella et al. [44]	Contour-based (projections of the outline of the signature) gray-level intensity-based	FD 1960(S) (20 (G), 20 (F))x49(A))	NN (MLP) (ME by Cascaded Multiple Experts)	FRR : 2,04%, FAR : 0,01% (RD), 4,29% (SP), 19,80 (SK)
P. S Deng et al. [49]	Wavelet transform	Training 500 (G) (from 50(A)) Test 500(G), 2500(F)	DTW	FRR : 5,60%, FAR : 10,98% (English signatures) FRR : 6,00%, FAR : 7,80% (Chinese signatures)
G. Dimauro et al. [59]	Projection-based, Slant-based, Geometric-based, Fourier Transform (Granlund descriptor)	Training 225 (G) (25(G)x9(A)) Test 450(G) (50(G)x9(A)), 450 (RF) (50(RF)x9(A)), 90(SK) (10(SK)x9(A))	Euclidean Distance, NN (ME by Majority Vote)	FRR : 2%, FAR : 0,5% (RF), 3,9% (SK) (with 22% Rejection Rate)
J.-P. Drouhard et al. [68]	Direction-based	Training 400 (S) Test 400 (S)	NN (BPN)	ϵ_1 : 3,22% (with $P(\omega_1)=P(\omega_2)=0.5$)
A.El Yacoubi et al. [71]	Grid-based (density of pixels)	Training 1600 (S) (from 40(A)) Test 2400(S) (from 60(A))	HMM (Cross validation)	FRR : 0,75%, FAR : 0,18% (on training datasets) FRR : 1,17%, FAR : 0,64% (on test datasets)
E.A. Fadhel and P. Bhattacharyya [76]	Global (Wavelet-based), statistical and geometrical	FD 300 (S) (from 31 (A))	NN	FRR : 6,2%, FAR : 5,5%
B. Fang et al. [84]	Projection-based	FD 1320 (G) (from 55(A)), 1320 (F) (from 55(A))	DTW	FRR : 22,1%, FAR : 23,5%
B. Fang and Y.Y. Tang [85]	Peripheral-based	Test 1320 (G), 1320 (F)	Mahalanobis distance	EER : 11,4%
M.A. Ferrer et al. [91]	Geometric-based	FD 3840 (G) (24(G)x160(A)), 4800 (F) (30(F)x160(A))	1) Euclidean Distance, 2) SVM, 3) HMM	1) FRR : 5,61%, (16,39%), FAR : 4,96% (15,50%) on RF (SF) 2) FRR : 3,23%, (15,41%) FAR : 2,65% (13,12%) on RF (SF) 3) FRR : 2,2%, (14,1%) FAR : 3,3% (12,6%) on RF (SF)
K. Huang and H. Yan [126]	Geometric based, grid-based	Test 504 (G), 3024 (F)	NN	FRR : 11,1%, FAR : 11,8%
K. Huang and H. Yan [128]	Geometric-based, Direction based	Training 424 (G) Test 848 (G), 7632 (F)	NN, Structural Matching (ME by Relaxation match.)	FRR : 6,3%, FAR : 8,2%
E. J. R. Justino et al. [144]	Graphometric-based	FD1 1600(S) (40(S)x40(A)) FD2 2400(S) (40(S)x60(A))	HMM (Cross validation)	FRR : 0,75%, FAR : 0,22% (FD1) FRR : 1%, FAR : 0,77% (FD2)
V. K. Madasu et al. [185]	Grid-based (normalized vector angle)	Training 255(G) (17 (G)x5(A)) Test 85(SF), 85(RF), 85(SK)	Fuzzy logic modeling	FRR : 0%, FAR : 3,5%
Y. Mizukami et al. [199]	Position	FD 400 (S) (200 (G), 200 (F))	Displacement function	EER : 24,9%
N. A. Murshed et al. [215]	Grid-based	FD 200 (S) (40(S)x 5(A))	NN (ARTMAP)	FRR : 7,27%, FAR : 11%
V.E.Ramesh and M.Narasimha Murty [274]	Geometric-based, Moment-based, Contour-based (envelope), wavelet transform	Training 225(G) ((15(G) x15(A), 195(F)(13(F) x15(A)) Test 75(G) (5(G)x15(A)), 150(F)(10(F)x15(A))	Confidence intervals, Minmax, N-dim boundary, NN, Hybrid approach	FRR : 10%, FAR : 2% (SP)
R. Sabourin et al. [281]	Shadow code-based	Test 800 (S) (40(S)x20(A))	Case a) kNN classifier Case b) min distance classifier	(Case a) ϵ_1 : 0,01% (k=1) (with $P(\omega_1)=P(\omega_2)=0.5$) (Case b) ϵ_1 : 0,87% (N=4) (with $P(\omega_1)=P(\omega_2)=0.5$)
R. Sabourin and J.-P Drouhard [282]	Direction based (Probability Density Function – PDF)	Training 400 (S) Test 400 (S)	NN	ϵ_1 : 4,07% (with $P(\omega_1)=P(\omega_2)=0.5$)
R. Sabourin et al. [283]	Shape Matrices	FD 800 (S) (from 20(A))	Pattern Matching	ϵ_1 : 0,84%
C. Santos et al. [295]	Graphometric based	Test 300 (G), 600 (F)	Euclidean distance + NN (MLP)	FRR : 10,33% FAR : 4,41% (RD), 1,67% (SP), 15,67% (sim. forgeries)
K. Ueda [318]	Pattern Image	Test 1000 (G), 1000 (F)	Pattern Matching	EER : 9,1%
X.-H. Xiao and G. Leedham [350]	Direction based, grid based	Training Genuine samples only (Case 1), Genuine samples + artificial forgeries (Case 2) Test 350 (G), 158 (SK), 230(RF)	NN (MLP)	FRR : 10,6%, FAR : 38,9% (SK) (Case 1) FRR : 9,2%, FAR : 17% (SK) (Case 2)

Full Database (FD), Signature (S), Genuine Signatures (G), Forgeries (F), Random Forgeries (RF), Simple Forgeries (SF), Skilled Forgeries (SK), Number of Authors (A)

a směrové hraniční znaky byly zvažovány pro popis signatury. Algoritmus statistického ověřování používal k ověření podpisu geometrické rysy a MLP. U sporných podpisů, u nichž bylo posouzení pixelových rysů neprůkazné, byl použit algoritmus strukturální shody s využitím směrových hraničních rysů. Justino *a kol.* [144] použili HMM-LR

se statickou charakteristikou založenou na hustotě a pseudodynamickou charakteristikou založenou na axiálním sklonu. V přístupu fuzzy modelování navrženém Madasuem *a kol.* [185] byla pro ověření podpisu použita dobře definovaná fuzzifikací funkce se strukturálními parametry. V tomto případě byl obraz podpisu rozdělen na pevně stanovený počet dílčích obrazů pomocí přístupu založeného na mřížce a normalizovaném